

Predicción del precio de vehículos usados

Versión traducida y mejorada en español del informe original

Proyecto de Machine Learning orientado a portfolio profesional

Autor	Héctor Ayuso Martín
Perfil	LinkedIn: hector-ayuso-martin
Documento base	used_car_price_prediction.pdf
Enfoque	EDA + ingeniería de variables + comparación de modelos

Resumen ejecutivo. Tras evaluar varios modelos de regresión, XGBoost con Early Stopping obtuvo el mejor rendimiento global, con MAE = 108.133,11, RMSE = 178.180,01 y $R^2 = 0,89$. El análisis muestra que variables como la transmisión automática, la marca y la antigüedad del vehículo aportan una señal predictiva muy relevante.

1. Objetivo y descripción del dataset

Objetivo. Desarrollar un sistema de Machine Learning capaz de estimar el *selling_price* de vehículos de segunda mano a partir de variables reales del mercado automovilístico.

Observaciones	Variables	Valores nulos	Variable objetivo
4.340	8	0	selling_price

Variables originales: name, year, selling_price, km_driven, fuel, seller_type, transmission y owner.

2. Hallazgos principales del análisis exploratorio

El análisis inicial confirmó que el precio de venta presenta una distribución claramente sesgada a la derecha y una gran cantidad de valores extremos altos. Esto justifica el uso de modelos robustos y explica por qué los algoritmos basados en árboles superan con claridad a la regresión lineal.



Distribución del precio de venta



Detección visual de outliers


- Existe una relación inversa entre kilometraje y precio, aunque con alta dispersión.
- Existe una relación positiva clara entre el año del vehículo y su precio.
- Diesel y Petrol dominan el dataset; las categorías minoritarias se agruparon como Other.
- La marca se convirtió en una variable esencial para capturar posicionamiento de mercado y valor residual.

3. Ingeniería de variables y preparación de datos

- Se extrajo la marca a partir del campo name.
- Se creó car_age como transformación más interpretable de year.
- Se creó km_per_year para contextualizar el kilometraje según la antigüedad.
- owner se codificó de forma ordinal para respetar su orden natural.
- Las variables categóricas se prepararon para modelado con One-Hot Encoding cuando el algoritmo lo requería.

4. Comparación de modelos

Se evaluaron cuatro enfoques de regresión con el mismo problema objetivo: un baseline lineal, un modelo de bagging (Random Forest), un modelo de boosting (XGBoost) y CatBoost. El criterio de comparación se basó en MAE, RMSE y R^2 sobre el conjunto de prueba.




Comparativa global de rendimiento de modelos

Modelo	MAE	RMSE	R ²
XGBoost + Early Stopping	108.133,11	178.180,01	0,89
Random Forest	113.032,43	201.630,34	0,86
CatBoost	122.193,21	222.494,46	0,82
Linear Regression (baseline)	209.395,38	371.532,50	0,51

Modelo ganador. XGBoost con Early Stopping fue el modelo con menor error y mayor capacidad explicativa. El mejor punto de entrenamiento se alcanzó en la iteración 365, lo que demuestra que el uso de early stopping ayudó a controlar el sobreajuste sin necesidad de fijar manualmente el número final de árboles.

5. Interpretación del modelo final

El análisis de importancia de variables del XGBoost final aporta una lectura útil del mercado: la configuración del vehículo y el posicionamiento de marca tienen un peso predictivo incluso superior al kilometraje bruto.



Top 10 de variables más influyentes según XGBoost

- La transmisión automática aparece como la señal más fuerte del modelo.
- Las marcas premium como BMW, Mercedes-Benz y Audi elevan de forma notable el precio esperado.
- El combustible diésel conserva una señal predictiva relevante en este dataset.
- La antigüedad del vehículo sigue siendo importante, aunque no domina por sí sola el modelo.

6. Conclusiones finales

- El proyecto consiguió construir un pipeline completo de Machine Learning para predicción de precios de vehículos usados.
- La combinación de EDA, ingeniería de variables y comparación de modelos permitió mejorar el rendimiento desde un baseline lineal ($R^2 = 0,51$) hasta un modelo final muy sólido ($R^2 = 0,89$).
- Los algoritmos de boosting demostraron ser especialmente eficaces en un problema tabular con variables mixtas y presencia de outliers.
- El trabajo deja preparado un modelo reutilizable para futuras integraciones en aplicaciones, APIs o dashboards.

7. Persistencia del modelo

El modelo final se guardó en la carpeta models como archivo serializado para su reutilización posterior. La extensión correcta es **xgb_used_car_model.pkl**

Nota. Esta versión en español reorganiza y sintetiza el contenido del notebook original para presentarlo como un informe más claro y legible para revisión profesional.